Méthodes de Monte-Carlo : intégration et filtrage

Mohamed Benloughmari Fatimetou Narjah

16 octobre 2026

Résumé

Ce compte rendu réunit deux applications des méthodes de Monte-Carlo. On étudie d'abord l'estimation d'intégrales par Monte-Carlo classique puis par échantillonnage d'importance, en comparant leurs variances, leur vitesse de convergence et en validant le théorème central limite. On aborde ensuite la localisation d'un robot mobile par filtrage particulaire, en analysant l'influence du nombre de particules, du nuage initial, des bruits du filtre, d'une panne capteur et de la stratégie de rééchantillonnage.

1 Introduction

L'objectif de ce TP est d'étudier différentes méthodes de Monte-Carlo pour approximer une intégrale et de comparer leur précision ainsi que leur coût de calcul.

On considère l'intégrale :

$$\mu = \int_0^1 \cos\left(\frac{\pi x}{2}\right) dx.$$

Sa valeur exacte est :

$$\mu = \frac{2}{\pi} \approx 0{,}63662.$$

Dans un premier temps, nous étudions la méthode de Monte-Carlo classique. Nous considérons ensuite la méthode d'échantillonnage d'importance (*Importance Sampling*), qui consiste à utiliser une densité de probabilité adaptée afin de réduire la variance de l'estimateur. Enfin, nous comparons les résultats théoriques aux résultats obtenus par simulation numérique, étudions la convergence des estimateurs et vérifions numériquement le théorème central limite.

2 Méthode de Monte-Carlo classique

2.1 Variance théorique

Pour $X \sim \mathcal{U}([0,1])$ et $g(x) = \cos\left(\frac{\pi x}{2}\right)$, on a :

$$\mathbb{E}[g(X)] = \frac{2}{\pi}, \qquad \mathbb{E}[g(X)^2] = \frac{1}{2}.$$

Ainsi,

$$\mathrm{Var}(g(X)) = \frac{1}{2} - \frac{4}{\pi^2} \approx 0{,}094715.$$

La variance de l'estimateur de Monte-Carlo est donc :

$$\mathrm{Var}(\widehat{\mu}_N) = \frac{1}{N}\left(\frac{1}{2} - \frac{4}{\pi^2}\right).$$

Pour $N = 50$, on obtient :

$$\boxed{\mathrm{Var}(\widehat{\mu}_{50}) \approx 0{,}0018943.}$$

2.2 Estimation empirique de la variance

Pour $N = 50$, nous réalisons $M = 100$ simulations indépendantes. La moyenne et la variance empiriques des estimations sont :

$$\overline{\mu} = 0{,}638955, \qquad V_{\text{emp}} = 0{,}00141784.$$

La variance théorique étant $V_{\text{th}} = 0{,}00189431$, on constate que la variance empirique est du même ordre de grandeur, mais présente un écart dû aux fluctuations aléatoires et au nombre limité de simulations.

2.3 Étude de la convergence en fonction de N

D'après la loi des grands nombres, l'estimateur $\widehat{\mu}_N$ converge vers $\mu = 2/\pi$ lorsque N augmente. Le graphique compare l'erreur quadratique moyenne (RMSE) empirique à l'erreur théorique :

$$\text{RMSE}(\widehat{\mu}_N) = \sqrt{\frac{\text{Var}(g(X))}{N}}.$$

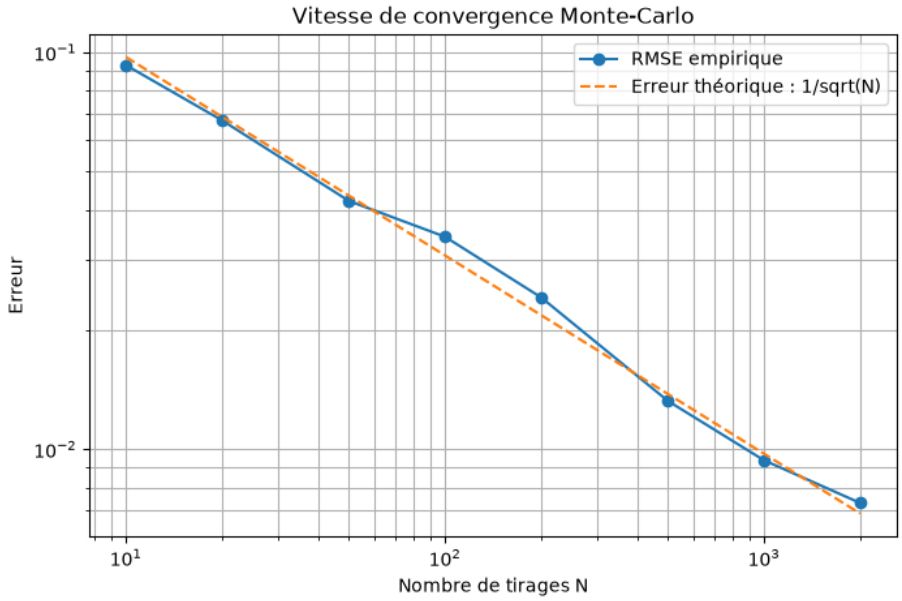


FIGURE 1 – Convergence de l'estimateur de Monte-Carlo en fonction du nombre de tirages N.

On observe que l'erreur diminue lorsque le nombre de tirages augmente et que la courbe empirique suit globalement la courbe théorique. L'erreur évolue en $1/\sqrt{N}$: pour diviser l'erreur par deux, il faut multiplier N par quatre.

2.4 Vérification numérique du TCL

Pour $N = 50$, nous réalisons $M = 10\,000$ simulations indépendantes. Chaque estimation est centrée et réduite :

$$Z_N = \frac{\widehat{\mu}_N - \mu}{\sqrt{\text{Var}(g(X))/N}}.$$

D'après le théorème central limite, Z_N suit approximativement une loi normale standard $\mathcal{N}(0, 1)$.

La simulation donne :

$$\mathbb{E}_{\text{emp}}[Z_N] \approx -0{,}045, \qquad \text{Var}_{\text{emp}}(Z_N) \approx 0{,}850.$$

L'histogramme obtenu présente une forme globalement en cloche, compatible avec une approximation normale. La moyenne empirique est proche de 0 et la variance proche de 1 ; les écarts observés sont dus aux fluctuations de la simulation.

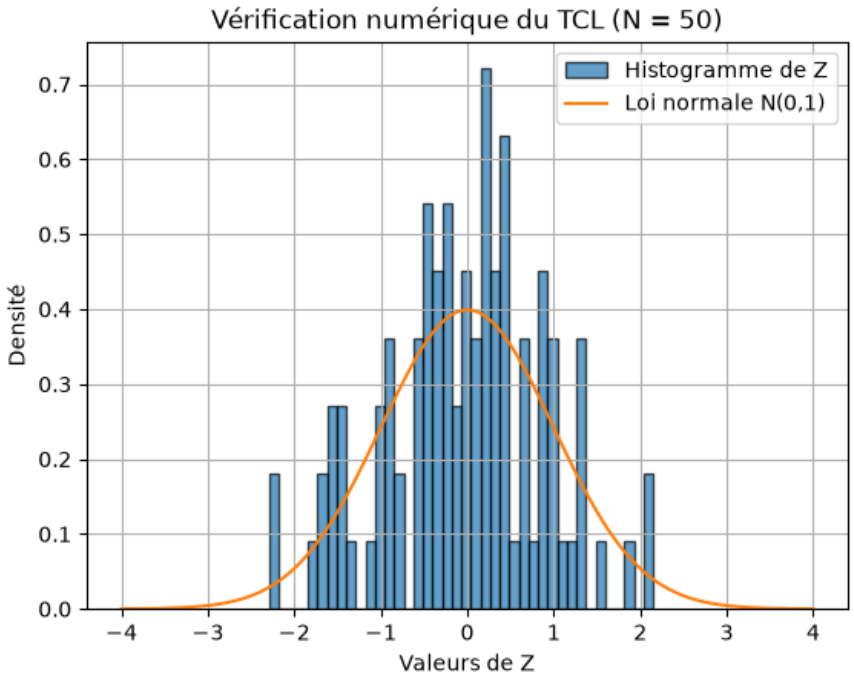


FIGURE 2 – Vérification numérique du TCL pour Monte-Carlo classique avec $N = 50$.

3 Importance sampling

3.1 Détermination de la densité d'importance optimale

La densité d'importance optimale est proportionnelle à $g(x)q(x)$ et s'écrit :

$$\boxed{\widetilde{q}_{\text{opt}}(x) = \frac{g(x)q(x)}{\mu} = \frac{\pi}{2}\cos\left(\frac{\pi x}{2}\right).}$$

Cette densité minimise la variance de l'estimateur. Elle n'est généralement pas directement utilisable, car sa normalisation dépend de μ, l'intégrale que l'on cherche à estimer.

3.2 Développement limité au voisinage de 0

Le développement limité de $\cos(u)$ au voisinage de 0 est :

$$\cos(u) = 1 - \frac{u^2}{2} + o(u^2).$$

En prenant $u = \frac{\pi x}{2}$, on obtient :

$$\boxed{g(x) = \cos\left(\frac{\pi x}{2}\right) = 1 - \frac{\pi^2 x^2}{8} + o(x^2).}$$

Ainsi, une approximation au voisinage de 0 est $g(x) \approx 1 - \frac{\pi^2 x^2}{8}$.

3.3 Validité de l'approximation comme densité

On ne peut pas utiliser directement $1 - \frac{\pi^2 x^2}{8}$ comme densité sur $[0,1]$, car une densité doit être positive ou nulle partout. Or, en $x = 1$:

$$1 - \frac{\pi^2}{8} < 0.$$

Cette approximation ne satisfait donc pas la condition de positivité d'une densité.

3.4 Normalisation de la densité proposée

On considère une densité de la forme $\widetilde{q}(x) = C(1 - x^2)$ sur $[0,1]$. Pour qu'elle soit une densité de probabilité, il faut :

$$\int_0^1 C(1 - x^2)\, dx = 1.$$

Ainsi,

$$C\left[x - \frac{x^3}{3}\right]_0^1 = 1 \quad \Longrightarrow \quad C\frac{2}{3} = 1.$$

Par conséquent,

$$\boxed{C = \frac{3}{2}}, \qquad \boxed{\widetilde{q}(x) = \frac{3}{2}(1 - x^2)}.$$

3.5 Tracé et comparaison des densités

Nous traçons les trois fonctions $q(x)$, $g(x)q(x)$ et $\widetilde{q}(x)$ sur $[0,1]$, avec :

$$q(x) = 1, \qquad g(x)q(x) = \cos\left(\frac{\pi x}{2}\right), \qquad \widetilde{q}(x) = \frac{3}{2}(1 - x^2).$$

La densité uniforme $q(x)$ est constante, tandis que $g(x)q(x)$ et $\widetilde{q}(x)$ sont décroissantes et s'annulent en $x = 1$. La densité d'importance proposée est plus élevée que $g(x)q(x)$ sur une grande partie de l'intervalle. Elle permet ainsi de générer davantage d'échantillons près de $x = 0$, où $g(x)q(x)$ est élevée.

4 Importance sampling avec acceptation-rejet

4.1 Détermination de la densité d'importance

Le développement limité de $g(x) = \cos(\pi x/2)$ au voisinage de 0 donne :

$$g(x) \approx 1 - \frac{\pi^2 x^2}{8}.$$

Cette approximation peut devenir négative sur $[0,1]$. On propose donc une densité de la forme $\widetilde{q}(x) = C(1 - x^2)$, où C est une constante. La condition de normalisation impose :

$$\int_0^1 C(1 - x^2)\, dx = 1 \quad \Longrightarrow \quad C = \frac{3}{2}.$$

La densité d'importance utilisée est donc :

$$\boxed{\widetilde{q}(x) = \frac{3}{2}(1 - x^2).}$$

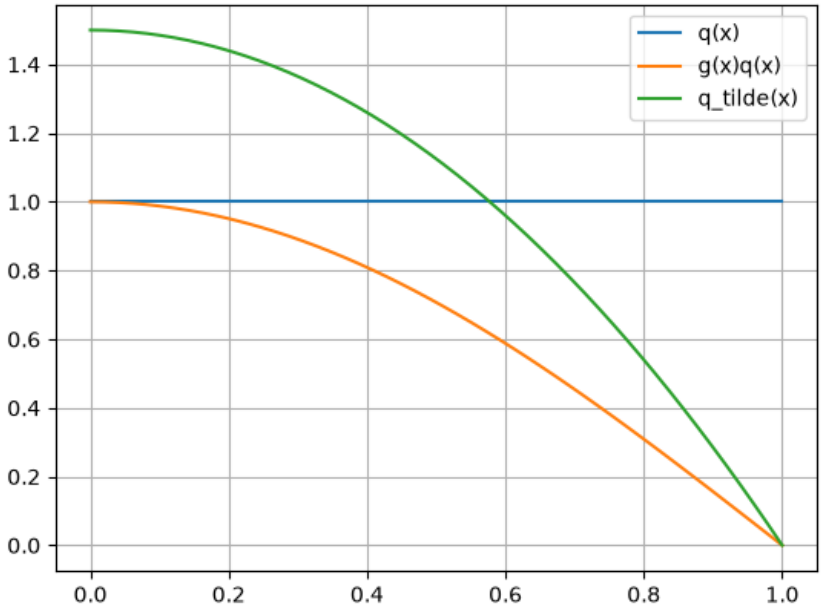


FIGURE 3 – Comparaison de $q(x)$, $g(x)q(x)$ et $\widetilde{q}(x)$.

4.2 Calcul de la variance théorique

L'estimateur d'importance sampling repose sur les poids

$$H(x) = \frac{g(x)q(x)}{\widetilde{q}(x)} = \frac{\cos(\pi x/2)}{\frac{3}{2}(1-x^2)}.$$

Sa variance théorique est :

$$\mathrm{Var}(\widehat{\mu}_N) = \frac{1}{N}\left[\int_0^1 \frac{g(x)^2 q(x)^2}{\widetilde{q}(x)}\,dx - \mu^2\right].$$

L'intégrale est calculée numériquement avec Python. Pour $N = 50$, on obtient :

$$\boxed{\mathrm{Var}(\widehat{\mu}_{50}) \approx 1{,}98166 \times 10^{-5}.}$$

4.3 Méthode d'acceptation-rejet

Pour générer des échantillons suivant la densité $\widetilde{q}(x) = \frac{3}{2}(1-x^2)$, on propose $X \sim \mathcal{U}([0,1])$ et $U \sim \mathcal{U}([0,1])$, puis on accepte X si :

$$U < 1 - X^2.$$

La probabilité d'acceptation théorique est :

$$P_a = \frac{1}{3/2}\int_0^1 \frac{3}{2}(1-x^2)\,dx = \boxed{\frac{2}{3} \approx 0{,}6667}.$$

Pour $M = 10^5$ propositions, la simulation donne :

$$P_{a,\mathrm{emp}} = 0{,}66903, \qquad \text{écart} = 0{,}00236.$$

Au total, 66 903 valeurs ont été acceptées. La probabilité empirique est proche de la valeur théorique, ce qui valide numériquement la méthode d'acceptation-rejet.

4.4 Estimation empirique de la variance

Nous réalisons $M = 10\,000$ simulations indépendantes, avec $N = 50$ échantillons acceptés pour chaque estimation. La variance empirique est calculée à partir des estimations $\widehat{\mu}_N^{(m)}$:

$$\widehat{V}_{\text{emp}} = \frac{1}{M-1} \sum_{m=1}^{M} \left(\widehat{\mu}_N^{(m)} - \overline{\mu} \right)^2 .$$

Les résultats obtenus sont :

$$\overline{\mu} = 0{,}636624, \qquad \widehat{V}_{\text{emp}} \approx 2{,}00982 \times 10^{-5}.$$

La variance empirique est proche de la variance théorique $1{,}98166 \times 10^{-5}$. Cela confirme la cohérence des résultats numériques.

5 Comparaison des deux méthodes

5.1 Comparaison théorique et empirique des variances

Pour $N = 50$, les variances théoriques des deux méthodes sont :

$$V_{\text{MC}} \approx 1{,}8943 \times 10^{-3}, \qquad V_{\text{IS}} \approx 1{,}9817 \times 10^{-5}.$$

Le rapport des variances vaut :

$$\boxed{\frac{V_{\text{MC}}}{V_{\text{IS}}} \approx 95{,}6.}$$

L'échantillonnage d'importance présente donc une variance environ 96 fois plus faible que Monte-Carlo classique. Pour une même précision, il nécessite théoriquement environ 96 fois moins d'échantillons.

Les simulations confirment ce résultat :

$$V_{\text{MC,emp}} \approx 1{,}4178 \times 10^{-3}, \qquad V_{\text{IS,emp}} \approx 2{,}0098 \times 10^{-5}.$$

5.2 Validation numérique du théorème central limite

Pour les deux méthodes, on centre et réduit les estimations :

$$Z = \frac{\widehat{\mu}_N - \mu}{\sqrt{\text{Var}(\widehat{\mu}_N)}}.$$

D'après le théorème central limite, la variable Z suit approximativement une loi normale standard $\mathcal{N}(0,1)$ pour $N = 50$.

Les histogrammes obtenus par simulation sont globalement proches de la densité de la loi normale standard. Cette observation est cohérente avec le théorème central limite pour les deux méthodes.

Pour obtenir une même précision, le nombre de tirages nécessaires est proportionnel à la variance de l'estimateur. Le rapport des budgets théoriques est donc :

$$\frac{N_{\text{MC}}}{N_{\text{IS}}} = \frac{V_{\text{MC}}}{V_{\text{IS}}} \approx 95{,}6.$$

Ainsi, l'échantillonnage d'importance nécessite théoriquement environ 96 fois moins d'échantillons pour obtenir une précision équivalente, sans tenir compte du coût de génération des échantillons.

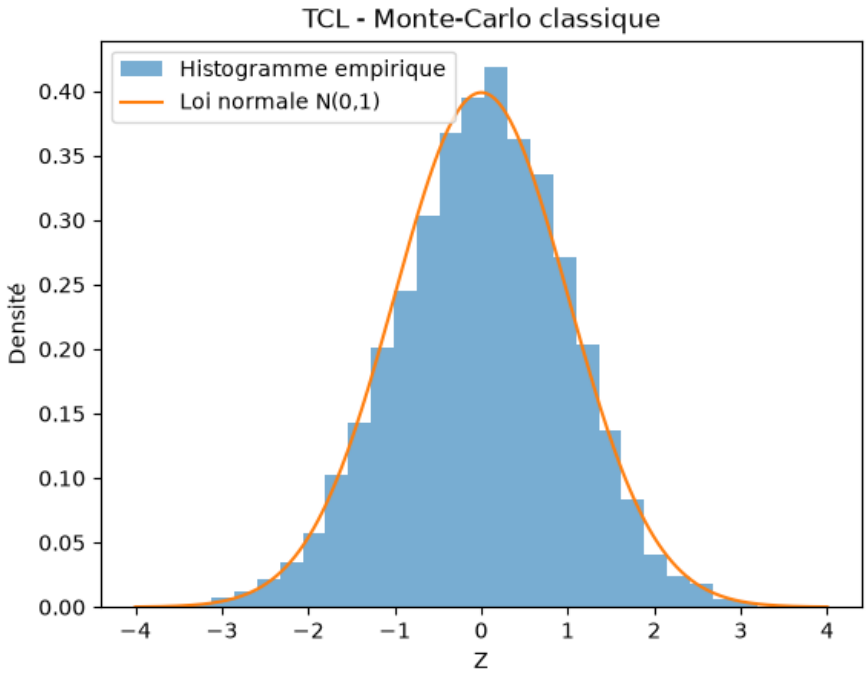


FIGURE 4 – Validation du TCL pour Monte-Carlo classique.

5.3 Variance avec la densité d'importance optimale

La densité d'importance optimale est :

$$\widetilde{q}_{\text{opt}}(x) = \frac{g(x)q(x)}{\mu} = \frac{\pi}{2}\cos\left(\frac{\pi x}{2}\right).$$

Avec cette densité, le poids de l'estimateur est constant :

$$\frac{g(x)q(x)}{\widetilde{q}_{\text{opt}}(x)} = \mu.$$

L'estimateur vaut donc exactement μ pour chaque simulation. Les résultats numériques donnent :

$$\overline{\mu} = 0{,}636620, \qquad V_{\text{emp}} = 0.$$

La variance est nulle, car la densité optimale nécessite de connaître μ, précisément la quantité à estimer. Elle est donc généralement inutilisable directement.

5.4 Importance sampling avec $\widetilde{q}(x) = 2(1-x)$

On considère la densité :

$$\widetilde{q}(x) = 2(1-x), \qquad x \in [0,1].$$

Sa fonction de répartition est

$$F(x) = \int_0^x 2(1-t)\,dt = 2x - x^2.$$

En posant $U = F(X)$ avec $U \sim \mathcal{U}([0,1])$, l'inversion de la fonction de répartition donne :

$$\boxed{X = 1 - \sqrt{1-U}.}$$

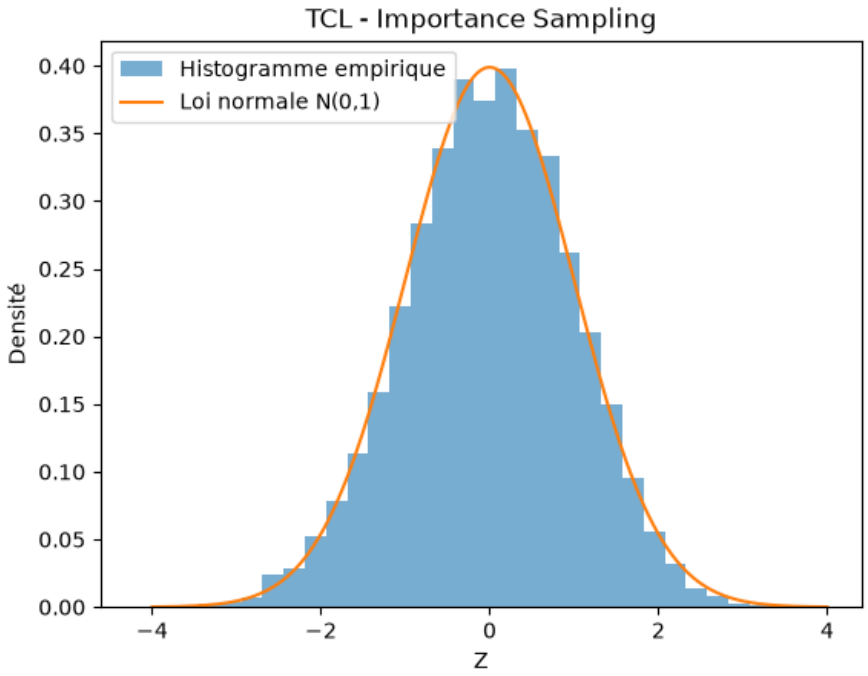


FIGURE 5 – Validation du TCL pour l'échantillonnage d'importance.

La variance théorique de l'estimateur pour $N = 50$ est :

$$V_{\mathrm{IS}} \approx 1{,}35694 \times 10^{-4}.$$

La simulation donne :

$$\overline{\mu}_{\mathrm{emp}} = 0{,}636706, \qquad V_{\mathrm{emp}} \approx 1{,}41963 \times 10^{-4}.$$

Pour comparaison, la variance de Monte-Carlo classique est $V_{\mathrm{MC}} \approx 1{,}89431 \times 10^{-3}$. La variance de cette méthode d'importance est donc plus faible que celle de Monte-Carlo classique.

6 Modèle

État. La pose du robot à l'instant k est $\mathbf{X}_k = (x_k, y_k, \theta_k)^\top \in \mathbb{R}^2 \times]-\pi, \pi]$. On note wrap la fonction qui ramène un angle dans $]-\pi, \pi]$ et $R(\theta)$ la rotation d'angle θ.

Évolution. Le déplacement $\mathbf{u}_k = (\delta x, \delta y, \delta\theta)$ est exprimé dans le repère du robot. La pose suivante est obtenue par composition de poses (fonction `tcomp`) :

$$\mathbf{X}_k = f(\mathbf{X}_{k-1}, \mathbf{u}_k) = \begin{pmatrix} x_{k-1} + \delta x \cos\theta_{k-1} - \delta y \sin\theta_{k-1} \\ y_{k-1} + \delta x \sin\theta_{k-1} + \delta y \cos\theta_{k-1} \\ \mathrm{wrap}(\theta_{k-1} + \delta\theta) \end{pmatrix}. \tag{1}$$

La commande vraie est $\mathbf{u}_k = (0,\ 0{,}1,\ 0{,}1\frac{\pi}{180}\sin(3\pi k/K))$: le robot avance de 0,1 m par pas avec un cap qui oscille lentement.

Odométrie. Le robot ne connaît que la commande bruitée

$$\tilde{\mathbf{u}}_k = \mathbf{u}_k + \boldsymbol{\varepsilon}_k, \qquad \boldsymbol{\varepsilon}_k \sim \mathcal{N}(0, Q), \qquad Q = \mathrm{diag}(0{,}02^2,\ 0{,}02^2,\ (1^\circ)^2). \tag{2}$$

Intégrer seulement l'odométrie donne une erreur qui s'accumule : l'erreur de cap est une marche aléatoire, et elle se transforme en erreur de position proportionnelle à la distance parcourue.

Observation. Il y a 20 amers $\mathbf{m}_j$ placés au hasard dans $[-60, 60]^2$. À chaque pas, le robot mesure la distance et l'angle relatif d'un amer j tiré au hasard :

$$\mathbf{z}_k = h_j(\mathbf{X}_k) + \boldsymbol{\eta}_k, \qquad h_j(\mathbf{X}) = \begin{pmatrix} \sqrt{(m_{j,x}-x)^2 + (m_{j,y}-y)^2} \\ \operatorname{wrap}\big(\operatorname{atan2}(m_{j,y}-y,\ m_{j,x}-x) - \theta\big) \end{pmatrix}, \tag{3}$$

avec $\boldsymbol{\eta}_k \sim \mathcal{N}(0, P_Y)$ et $P_Y = \operatorname{diag}(0{,}5^2,\ (1^\circ)^2)$. La fonction h_j est non linéaire : une seule mesure place le robot sur un cercle autour de l'amer, donc la loi de $\mathbf{X}_k$ sachant les mesures n'est pas gaussienne en général.

Bruits du filtre. Le filtre utilise ses propres covariances Q_{est} et $P_{Y,\text{est}}$, égales par défaut à $2Q$ et $2P_Y$.

7 Filtre particulaire

7.1 Filtrage bayésien

On cherche la loi a posteriori $p(\mathbf{X}_k \mid \mathbf{z}_{1:k})$. Comme $(\mathbf{X}_k)$ est une chaîne de Markov et que les mesures sont indépendantes sachant l'état, elle se calcule récursivement en deux étapes.

Prédiction (Chapman–Kolmogorov).

$$p(\mathbf{X}_k \mid \mathbf{z}_{1:k-1}) = \int p(\mathbf{X}_k \mid \mathbf{X}_{k-1})\, p(\mathbf{X}_{k-1} \mid \mathbf{z}_{1:k-1})\, d\mathbf{X}_{k-1}. \tag{4}$$

Correction (Bayes).

$$p(\mathbf{X}_k \mid \mathbf{z}_{1:k}) = \frac{p(\mathbf{z}_k \mid \mathbf{X}_k)\, p(\mathbf{X}_k \mid \mathbf{z}_{1:k-1})}{\int p(\mathbf{z}_k \mid \mathbf{X})\, p(\mathbf{X} \mid \mathbf{z}_{1:k-1})\, d\mathbf{X}}. \tag{5}$$

Ces intégrales n'ont une solution exacte que dans le cas linéaire gaussien (filtre de Kalman). Ici f et h_j sont non linéaires, donc on les approche par Monte-Carlo.

7.2 Approximation de Monte-Carlo

Si $\mathbf{X}^{(1)}, \dots, \mathbf{X}^{(N)}$ sont tirés selon une loi p, alors

$$\hat{\mu}_N = \frac{1}{N}\sum_{i=1}^{N} g(\mathbf{X}^{(i)}) \xrightarrow[N\to\infty]{p.s.} \mathbb{E}_p[g(\mathbf{X})], \qquad \mathbb{V}(\hat{\mu}_N) = \frac{\mathbb{V}_p(g(\mathbf{X}))}{N}. \tag{6}$$

L'erreur décroît donc en $1/\sqrt{N}$. On ne sait pas tirer directement selon $p(\mathbf{X}_k \mid \mathbf{z}_{1:k})$: on utilise l'échantillonnage d'importance. On tire selon une densité q et on corrige par des poids :

$$\mathbb{E}_p[g(\mathbf{X})] = \mathbb{E}_q\!\left[\frac{p(\mathbf{X})}{q(\mathbf{X})}\, g(\mathbf{X})\right] \approx \sum_{i=1}^{N} w^{(i)} g(\mathbf{X}^{(i)}), \qquad w^{(i)} \propto \frac{p(\mathbf{X}^{(i)})}{q(\mathbf{X}^{(i)})}, \quad \sum_i w^{(i)} = 1. \tag{7}$$

La loi a posteriori est alors représentée par un nuage de particules pondérées $\{\mathbf{X}_k^{(i)}, w_k^{(i)}\}$.

7.3 Filtre bootstrap

Proposition 1. Si on prend comme densité d'importance la dynamique, $q(\mathbf{X}_k \mid \mathbf{X}_{k-1}^{(i)}) = p(\mathbf{X}_k \mid \mathbf{X}_{k-1}^{(i)})$, alors les poids se mettent à jour par

$$w_k^{(i)} \propto w_{k-1}^{(i)}\, p(\mathbf{z}_k \mid \mathbf{X}_k^{(i)}). \tag{8}$$

Démonstration. Pour une trajectoire, la cible vérifie

$$p(\mathbf{X}_{0:k} \mid \mathbf{z}_{1:k}) \propto p(\mathbf{z}_k \mid \mathbf{X}_k)\, p(\mathbf{X}_k \mid \mathbf{X}_{k-1})\, p(\mathbf{X}_{0:k-1} \mid \mathbf{z}_{1:k-1})$$

et la densité d'importance est $q(\mathbf{X}_{0:k}) = p(\mathbf{X}_k \mid \mathbf{X}_{k-1})\, q(\mathbf{X}_{0:k-1})$. Le rapport des deux donne $w_k \propto \dfrac{p(\mathbf{z}_k \mid \mathbf{X}_k)\, p(\mathbf{X}_k \mid \mathbf{X}_{k-1})}{p(\mathbf{X}_k \mid \mathbf{X}_{k-1})}\, w_{k-1} = p(\mathbf{z}_k \mid \mathbf{X}_k)\, w_{k-1}$. □

La prédiction (4) se fait donc en simulant chaque particule avec le modèle d'évolution, et la correction (5) en multipliant les poids par la vraisemblance.

Dégénérescence et rééchantillonnage. Avec (8), la variance des poids augmente avec k et, au bout de quelques pas, une seule particule porte presque tout le poids. On le mesure par la taille effective

$$N_{\text{eff}} = \frac{1}{\sum_{i=1}^{N} (w_k^{(i)})^2} \in [1, N], \tag{9}$$

qui vaut N si les poids sont égaux et 1 si une particule a tout le poids. Le rééchantillonnage tire N particules parmi les anciennes avec probabilités $w_k^{(i)}$ (les lourdes sont dupliquées, les légères éliminées) puis remet les poids à $1/N$. Le code le fait à chaque pas ; le filtre SIR ne le fait que si $N_{\text{eff}} < \theta N$.

Estimation. On utilise la moyenne et la covariance pondérées

$$\hat{\mathbf{X}}_k = \sum_i w_k^{(i)} \mathbf{X}_k^{(i)}, \qquad \hat{P}_k = \sum_i w_k^{(i)} (\mathbf{X}_k^{(i)} - \hat{\mathbf{X}}_k)(\mathbf{X}_k^{(i)} - \hat{\mathbf{X}}_k)^\top. \tag{10}$$

7.4 Cas du robot

Dans le code, les étapes deviennent :

1. **Initialisation :** $\mathbf{X}_0^{(i)} = \mathbf{X}_0 + \text{diag}(1, 1, 0{,}1)\, \boldsymbol{\xi}^{(i)}$, $\boldsymbol{\xi}^{(i)} \sim \mathcal{N}(0, I_3)$ (écarts-types 1 m, 1 m, 0,1 rad).
2. **Prédiction :** $\mathbf{X}_k^{(i)} = f(\mathbf{X}_{k-1}^{(i)},\ \tilde{\mathbf{u}}_k + \mathbf{v}^{(i)})$ avec $\mathbf{v}^{(i)} \sim \mathcal{N}(0, Q_{\text{est}})$.
3. **Correction :** innovation $\boldsymbol{\nu}^{(i)} = \mathbf{z}_k - h_j(\mathbf{X}_k^{(i)})$ (angle ramené dans $]-\pi, \pi]$), puis

$$w^{(i)} \propto \exp\Big(-\tfrac{1}{2}\, \boldsymbol{\nu}^{(i)\top} P_{Y,\text{est}}^{-1}\, \boldsymbol{\nu}^{(i)} \Big) + 10^{-3}. \tag{11}$$

   La constante de la gaussienne disparaît à la normalisation. Comme on rééchantillonne à chaque pas, $w_{k-1}^{(i)} = 1/N$ et (8) se réduit à la vraisemblance. Le terme 10^{-3} évite que tous les poids soient nuls.
4. **Estimation** de $\hat{\mathbf{X}}_k$ et $\hat{\sigma}_x = \sqrt{(\hat{P}_k)_{11}}$, puis **rééchantillonnage** à faible variance.

Protocole. Toutes les expériences utilisent $K = 2000$ pas, la même carte et les mêmes mesures (graine fixée), et sauf mention contraire $N = 1000$ et les réglages du code. On regarde l'erreur sur x, $e_x = \hat{x}_k - x_k$, et l'enveloppe $\pm 3\hat{\sigma}_x$ donnée par le filtre : si le filtre est cohérent, l'erreur doit rester dans l'enveloppe. Tout le code est dans `tp_filtre_particulaire.py`.

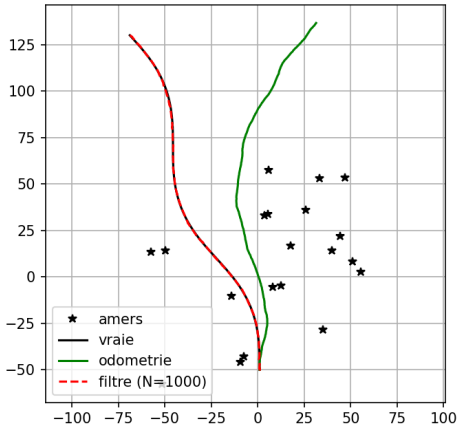


FIGURE 6 – Scénario : amers, trajectoire vraie, odométrie et estimée du filtre.

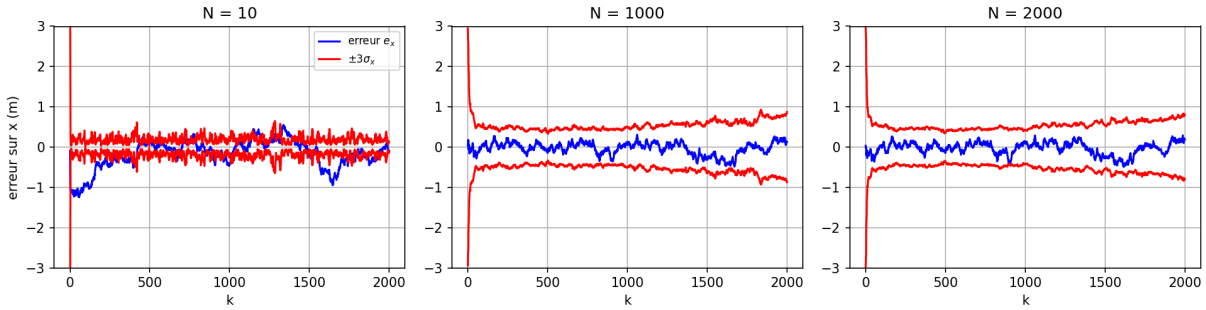


FIGURE 7 – Erreur e_x et enveloppe $\pm 3\hat{\sigma}_x$ pour $N = 10$, 1000, 2000.

8 Nombre de particules

Avec $N = 10$, l'erreur est grande et sort souvent de l'enveloppe : le filtre annonce une incertitude trop petite (figure 7). Avec si peu de particules, le rééchantillonnage duplique toujours les mêmes et le nuage perd sa diversité. À partir de $N = 500$, l'erreur ne diminue presque plus (tableau 1) : elle est limitée par le bruit des capteurs et non plus par l'approximation de Monte-Carlo, dont l'erreur en $1/\sqrt{N}$ devient négligeable. Les courbes pour $N = 1000$ et $N = 2000$ sont presque identiques, alors que le temps de calcul est proportionnel à N. Quelques centaines de particules suffisent donc dans ce scénario.

9 Variance initiale

On multiplie les écarts-types du nuage initial par un facteur s, et on considère deux cas :

— **cas A** : le nuage est centré sur la vraie pose $\mathbf{X}_0$, comme dans le code fourni ;

— **cas B** : le nuage est centré sur une estimée fausse $\mathbf{X}_0 + (3,\ -3,\ 0{,}3)$, ce qui est plus réaliste.

On teste aussi une initialisation uniforme sur toute la carte (localisation globale).

Cas A. Quand le nuage est centré sur la vraie pose, un petit nuage est le meilleur choix : pour $s = 0{,}1$ et $s = 1$ l'erreur est faible dès le départ (figure 8, haut). Le filtre connaît déjà la bonne position et n'a rien à chercher. Avec $s = 10$, les particules sont dispersées sur plusieurs dizaines de mètres et peu d'entre elles sont proches de la vérité : l'estimée saute pendant les premiers pas (erreur jusqu'à 13,7 m), puis se recale lentement. Avec $s = 50$, le filtre se perd.

N	moyenne $\lvert e_x \rvert$ (m)	variance e_x (m^2)	temps (s)
10	0,294	0,129	0,3
500	0,126	0,025	10,4
1000	0,120	0,023	20,7
1500	0,127	0,026	30,9
2000	0,123	0,024	41,2

TABLE 1 – Erreur et temps de calcul en fonction de N.

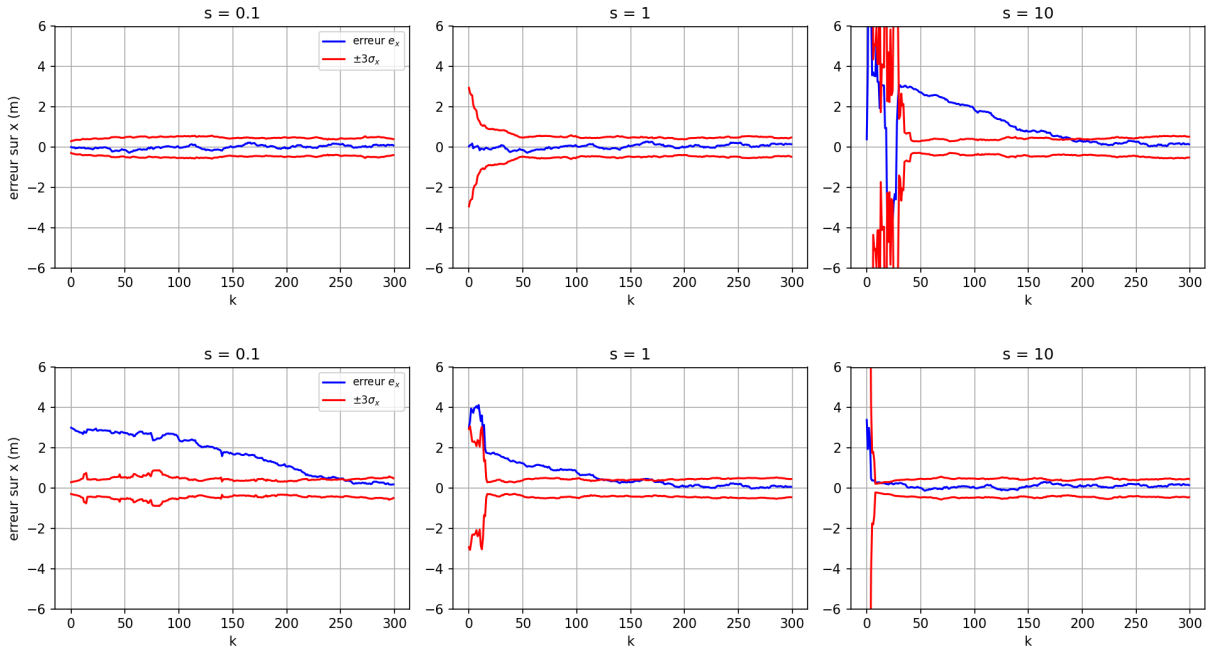


FIGURE 8 – Nuage initial d'écart-type $s \cdot \mathrm{diag}(1, 1, 0{,}1)$, 300 premiers pas. Haut : cas A (centré sur $\mathbf{X}_0$). Bas : cas B (centré sur $\mathbf{X}_0 + (3, -3, 0{,}3)$).

Cas B. Quand le nuage est centré à côté de la vraie pose, la conclusion change. Si le nuage est trop petit ($s = 0{,}1$ ou 1), il ne contient pas la vraie position. Toutes les particules ont une vraisemblance très faible, les poids sont presque égaux et les mesures corrigent peu : l'erreur de 3 m ne diminue que lentement, en 150 à 250 pas, grâce au bruit Q_{est} qui étale le nuage (figure 8, bas). Pendant ce temps, le filtre est trop confiant : l'erreur est très au-dessus de l'enveloppe. Avec $s = 10$, le nuage couvre la vraie position et le filtre se recale en quelques pas. Avec $s = 50$, le filtre se perd complètement.

Localisation globale. Avec le nuage uniforme, le filtre fait de grandes erreurs au début (jusqu'à 19 m) mais finit par trouver le robot pour cette simulation (0,22 m d'erreur finale). Ce résultat dépend du hasard : avec 1000 particules sur toute la carte, très peu sont compatibles avec les premières mesures, et le filtre peut aussi se fixer sur une mauvaise position.

La dispersion initiale doit donc représenter l'incertitude réelle sur la pose de départ : petite si on la connaît bien (cas A), assez grande pour couvrir l'erreur si on la connaît mal (cas B), mais jamais trop grande pour le nombre de particules.

cas	nuage initial	moyenne $\lvert e_x \rvert$ (m)	max $\lvert e_x \rvert$ (m)	$\lvert e_x \rvert$ final (m)
A	$s = 0{,}1$	0,11	0,4	0,15
A	$s = 1$	0,12	0,5	0,13
A	$s = 10$	0,30	13,7	0,10
A	$s = 50$	10,3	31,2	14,4
B	$s = 0{,}1$	0,36	3,0	0,26
B	$s = 1$	0,21	4,1	0,18
B	$s = 10$	0,13	3,4	0,05
B	$s = 50$	84,9	192,8	192,8
–	uniforme	4,24	19,1	0,22

TABLE 2 – Influence de la dispersion du nuage initial ($N = 1000$).

10 Bruits du filtre

On pose $Q_{\text{est}} = \alpha_Q\, Q$ et $P_{Y,\text{est}} = \alpha_R\, P_Y$: $\alpha < 1$ signifie que le filtre sous-estime le bruit, $\alpha = 1$ qu'il le connaît exactement, $\alpha > 1$ qu'il le surestime. On fait varier un seul facteur, l'autre restant à 2.

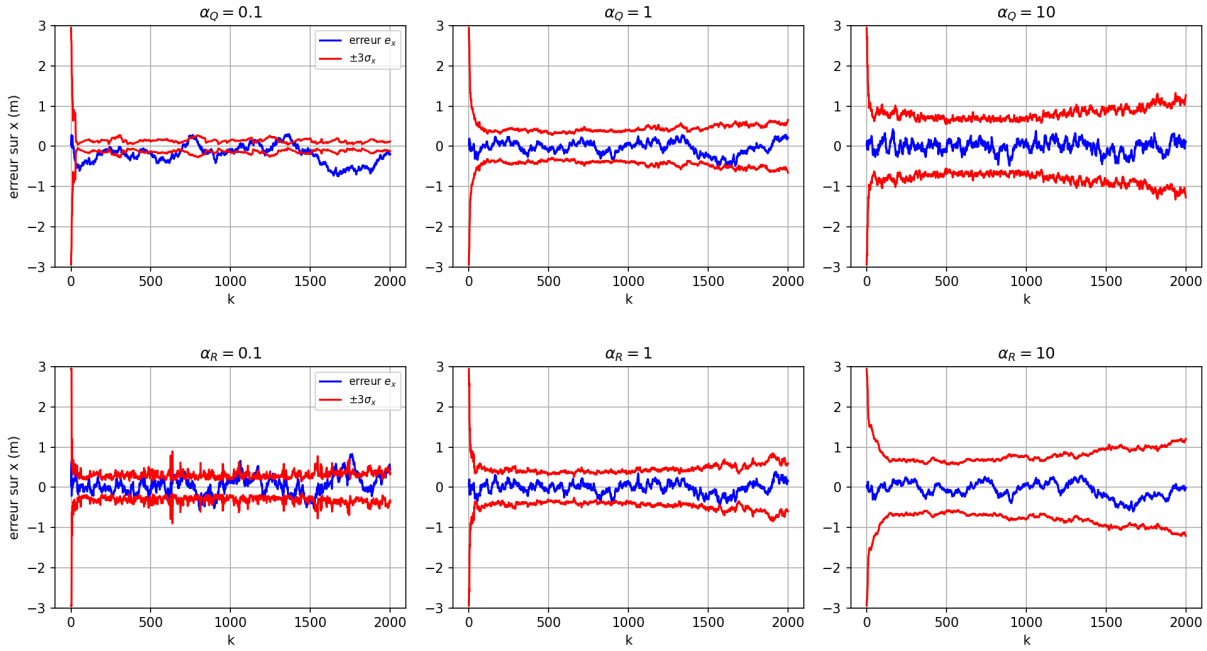


FIGURE 9 – Bruit de mouvement (haut) et de mesure (bas) sous-estimé, exact ou surestimé.

Bruit de mouvement. Avec $\alpha_Q = 0{,}1$, le nuage ne s'étale pas assez pour suivre la dérive réelle de l'odométrie. L'erreur double et sort souvent de l'enveloppe, qui est trop étroite (figure 9, haut). Avec $\alpha_Q = 10$, l'erreur ne change presque pas, mais le nuage est trop large : le filtre reste cohérent avec une enveloppe beaucoup trop grande.

Bruit de mesure. Avec $\alpha_R = 0{,}1$, la vraisemblance est trop étroite : seules quelques particules gardent du poids et l'estimée suit le bruit de chaque mesure. L'erreur augmente et l'enveloppe est trop petite. Avec $\alpha_R = 10$, les mesures comptent moins, l'erreur augmente légèrement et l'enveloppe est beaucoup trop large.

	α_Q varie		α_R varie	
α	moy. $\lvert e_x \rvert$ (m)	moy. $\hat{\sigma}_x$ (m)	moy. $\lvert e_x \rvert$ (m)	moy. $\hat{\sigma}_x$ (m)
0,1	0,253	0,051	0,188	0,107
1	0,128	0,152	0,113	0,156
2	0,120	0,184	0,120	0,184
10	0,121	0,275	0,157	0,276

TABLE 3 – Erreur moyenne et écart-type annoncé selon les bruits du filtre.

Sous-estimer un bruit rend donc le filtre trop confiant ; le surestimer le rend prudent mais robuste. Les réglages $\alpha = 1$ et $\alpha = 2$ (choix du code) donnent des erreurs très proches ; $\alpha = 2$ garde une marge de sécurité si les bruits réels sont mal connus.

11 Panne capteur

On supprime les mesures pour $400 < k < 500$. Pendant la panne, le filtre ne fait que la prédiction (4) : la loi a posteriori s'élargit à chaque pas et seul Q_{est} fixe la vitesse de cet élargissement.

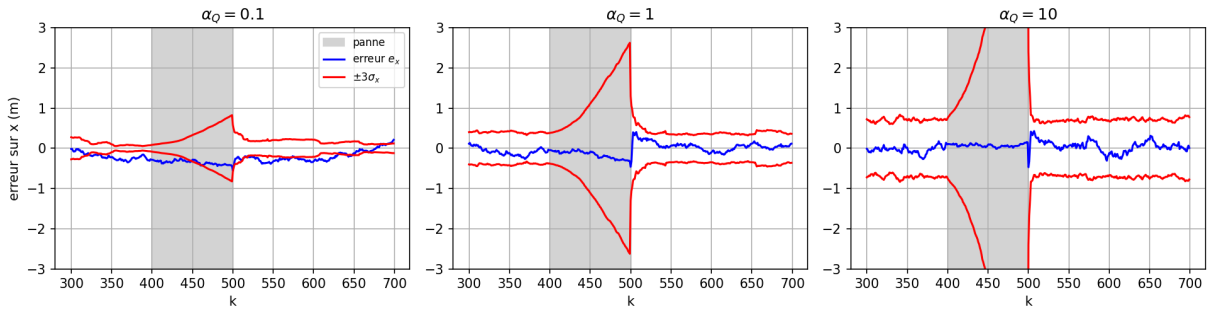


FIGURE 10 – Panne capteur (zone grise) pour $\alpha_Q = 0{,}1$, 1, 10.

α_Q	max $\lvert e_x \rvert$ pendant (m)	$3\hat{\sigma}_x$ en fin de panne (m)	max $\lvert e_x \rvert$ après (200 pas)
0,1	0,45	0,82	0,55
1	0,33	2,62	0,46
10	0,16	7,58	0,47

TABLE 4 – Comportement pendant et après la panne $400 < k < 500$.

Dans les trois cas, l'erreur reste inférieure à 0,5 m : l'odométrie dérive peu pendant ces 100 pas. La différence est dans l'enveloppe, qui s'ouvre pendant la panne puis se referme dès le retour des mesures (figure 10). Avec $\alpha_Q = 0{,}1$, elle s'ouvre trop peu et l'erreur en sort : le filtre se croit précis alors qu'il n'a plus de mesures, et il est un peu moins bon après la panne. Avec $\alpha_Q = 10$, elle s'ouvre beaucoup trop (7,6 m pour une erreur de 0,2 m) et la première mesure après la panne provoque un saut de l'estimée. Le modèle exact $\alpha_Q = 1$ donne une incertitude qui grandit de façon réaliste et un recalage rapide.

12 Filtre SIR

On garde maintenant les poids d'un pas à l'autre avec (8) et on ne rééchantillonne que si $N_{\text{eff}} < \theta N$.

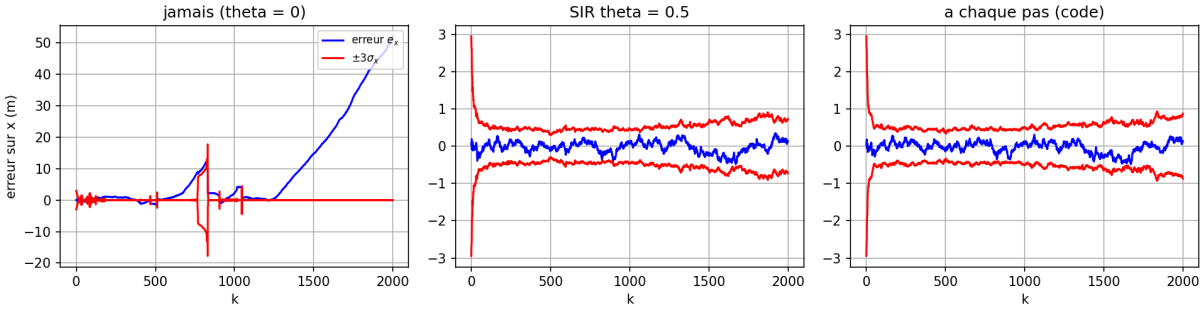


FIGURE 11 – Sans rééchantillonnage, SIR avec $\theta = 0{,}5$, et rééchantillonnage à chaque pas.

rééchantillonnage	moyenne $\lvert e_x \rvert$ (m)	max $\lvert e_x \rvert$ (m)	nombre
jamais ($\theta = 0$)	10,2	52,1	0
SIR $\theta = 0{,}5$	0,124	0,48	943
à chaque pas	0,120	0,49	1999

TABLE 5 – Influence du rééchantillonnage.

Sans rééchantillonnage, les poids dégénèrent en quelques pas : une seule particule porte tout le poids, l'enveloppe devient nulle et l'estimée dérive comme une odométrie, jusqu'à 52 m d'erreur (figure 11). Le rééchantillonnage est donc indispensable. Le SIR avec $\theta = 0{,}5$ donne presque la même précision que le code fourni avec deux fois moins de rééchantillonnages (tableau 5). Rééchantillonner à chaque pas n'est donc pas nécessaire : cela coûte du calcul et réduit inutilement la diversité du nuage quand les poids sont encore équilibrés. Le SIR évite aussi de rééchantillonner pendant une panne, où les poids ne changent pas.

13 Conclusion

Ce TP a mis en évidence deux usages complémentaires des méthodes de Monte-Carlo. Pour l'intégration, l'échantillonnage d'importance réduit fortement la variance de l'estimateur dès lors que la densité d'importance est bien choisie, ce qui diminue d'autant le nombre de tirages nécessaires pour une précision donnée. Pour la localisation, le filtre particulaire approxime la loi a posteriori par un nuage de particules pondérées : quelques centaines suffisent, le nuage initial doit refléter l'incertitude réelle et il vaut mieux surestimer que sous-estimer les bruits. Dans les deux cas, la qualité du résultat repose sur un bon choix de densité d'importance ou de proposition.